

# МЕТРИКИ КАЧЕСТВА В ЗАДАЧАХ РЕГРЕССИИ

---

# МЕТРИКИ КАЧЕСТВА

---

- › Для задания функционала ошибки
  - ▶ Используется при обучении
- › Для подбора гиперпараметров
  - ▶ Используется при измерении качества на кросс-валидации
- › Для оценивания итоговой модели
  - ▶ Пригодна ли модель для решения задачи?

# СРЕДНЕКВАДРАТИЧНАЯ ОШИБКА

---

$$\text{MSE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

- › Легко минимизировать
- › Сильно штрафует за большие ошибки

# СРЕДНЯЯ АБСОЛЮТНАЯ ОШИБКА

---

$$\text{MAE}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} |a(x_i) - y_i|$$

- › Сложнее минимизировать
- › Выше устойчивость к выбросам

# КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ

---

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^{\ell} (a(x_i) - y_i)^2}{\sum_{i=1}^{\ell} (y_i - \bar{y})^2}$$

›  $\bar{y} = \frac{1}{\ell} \sum_{i=1}^{\ell} y_i$  — средний ответ

› Доля дисперсии, объяснённая моделью, в общей дисперсии ответов

› Значение можно интерпретировать

# КОЭФФИЦИЕНТ ДЕТЕРМИНАЦИИ

---

$$R^2(a, X) = 1 - \frac{\sum_{i=1}^l (a(x_i) - y_i)^2}{\sum_{i=1}^l (y_i - \bar{y})^2}$$

- ›  $0 \leq R^2 \leq 1$  (для разумных моделей)
- ›  $R^2 = 1$  — идеальная модель
- ›  $R^2 = 0$  — модель на уровне константной
- ›  $R^2 < 0$  — модель хуже константной

# НЕСИММЕТРИЧНЫЕ ПОТЕРИ


---

- › Пример: прогнозирование спроса на ноутбуки
- › Заниженный прогноз — потеря лояльности и потенциальной прибыли
- › Завышенный прогноз — расходы на хранение

# КВАНТИЛЬНАЯ ОШИБКА

---

$$\rho_{\tau}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} ((\tau - 1)[y_i < a(x_i)] + \tau[y_i \geq a(x_i)])(y_i - a(x_i))$$





# ВЕРОЯТНОСТНЫЙ СМЫСЛ

---

- › Пример: объект  $x$  повторяется в выборке  $n$  раз
- › Ответы:  $y_1, y_2, \dots, y_n$
- ›  $a(x) = ?$

# ВЕРОЯТНОСТНЫЙ СМЫСЛ

---

- › Какой прогноз оптимален для  $x$  ?
- › **MSE** — средний ответ
- › **MAE** — медиана ответов
- › Квантильная ошибка:  $\tau$ –квантиль

# РЕЗЮМЕ

---

› **MSE** и **MAE**

›  $\mathbb{R}^2$  — интерпретируемый вариант **MSE**

› Квантильная ошибка — для несимметричных потерь

# МЕТРИКА КАЧЕСТВА КЛАССИФИКАЦИИ

---

# КАЧЕСТВО КЛАССИФИКАЦИИ

---

› Доля неправильных ответов:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

# КАЧЕСТВО КЛАССИФИКАЦИИ

---

› Доля правильных ответов (accuracy):

$$\text{accuracy}(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

# НЕСБАЛАНСИРОВАННЫЕ ВЫБОРКИ

---

› Пример:

- ▶ Класс  $-1$ : 950 объектов
- ▶ Класс  $+1$ : 50 объектов

›  $a(x) = -1$

› Доля правильных ответов:  $0.95$

# НЕСБАЛАНСИРОВАННЫЕ ВЫБОРКИ

---

›  $q_0$  — доля объектов самого крупного класса

› Доля разумных алгоритмов:

$$\text{accuracy} \in [q_0, 1]$$



# ЦЕНЫ ОШИБОК

---

- › Пример: кредитный скоринг
- › Модель 1:
  - ▶ 80 кредитов вернули
  - ▶ 20 кредитов не вернули
- › Модель 2:
  - ▶ 48 кредитов вернули
  - ▶ 2 кредита не вернули
- › Кто лучше?

# РЕЗЮМЕ

---

- › Доля верных ответов
- › Могут быть проблемы на несбалансированных выборках
- › Ошибки могут иметь разную цену

# Точность и полнота

---

# ЦЕНЫ ОШИБОК

---

- » Что хуже?
  - ▶ Выдать кредит «плохому» клиенту
  - ▶ Не выдать кредит «хорошему» клиенту
- » Доля верных ответов не учитывает цены ошибок

| МАТРИЦА ОШИБОК |                        |                        |
|----------------|------------------------|------------------------|
|                | $y = 1$                | $y = -1$               |
| $a(x) = 1$     | True<br>Positive (TP)  | False<br>Positive (FP) |
| $a(x) = -1$    | False<br>Negative (FN) | True<br>Negative (TN)  |

# МАТРИЦА ОШИБОК

---

› Модель  $a_1(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |

› Модель  $a_2(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

# ТОЧНОСТЬ (PRECISION)

---

- › Можно ли доверять классификатору при  $a(x) = 1$ ?

$$\text{precision}(a, X) = \frac{TP}{TP+FP}$$

# МАТРИЦА ОШИБОК

---

› Модель  $a_1(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |

› Модель  $a_2(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

›  $\text{precision}(a_1, X) = 0.8$  ›  $\text{precision}(a_2, X) = 0.96$



# ПОЛНОТА (RECALL)

---

- » Как много положительных объектов находит классификатор?

$$\text{recall}(a, X) = \frac{TP}{TP+FN}$$

# МАТРИЦА ОШИБОК

---

› Модель  $a_1(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 80      | 20       |
| $a(x) = -1$ | 20      | 80       |

› Модель  $a_2(x)$ :

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 48      | 2        |
| $a(x) = -1$ | 52      | 98       |

›  $\text{recall}(a_1, X) = 0.8$

›  $\text{recall}(a_2, X) = 0.48$

# КРЕДИТНЫЙ СКОРИНГ

---

- › Неудачных кредитов должно быть не больше 5%
- › Ограничение:  $\text{precision}(a, X) \geq 0.95$
- › Максимизируем полноту

# МЕДИЦИНСКАЯ ДИАГНОСТИКА

---

- › Надо найти не менее 80% больных
- › Ограничение:  $\text{recall}(a, X) \geq 0.8$
- › Максимизируем точность

# НЕСБАЛАНСИРОВАННЫЕ ВЫБОРКИ

---

›  $\text{accuracy}(a, X) = 0.99$

›  $\text{precision}(a, X) = 0.33$

›  $\text{recall}(a, X) = 0.1$

|             | $y = 1$ | $y = -1$ |
|-------------|---------|----------|
| $a(x) = 1$  | 10      | 20       |
| $a(x) = -1$ | 90      | 10000    |

# РЕЗЮМЕ

---

- › Матрица ошибок
- › Точность и полнота позволяют балансировать важность разных типов ошибок
- › Точность и полнота хорошо работают на несбалансированных выборках

# ОБЪЕДИНЕНИЕ ТОЧНОСТИ И ПОЛНОТЫ

---

# ТОЧНОСТЬ И ПОЛНОТА

---


- › Точность — можно ли доверять классификатору при  $a(x) = 1$ ?
- › Полнота — как много положительных объектов находит  $a(x)$ ?
- › Хорошо работают на несбалансированных выборках
- › Как объединить?



# АРИФМЕТИЧЕСКОЕ СРЕДНЕЕ

---

›  $A = \frac{1}{2}(\text{precision} + \text{recall})$



# АРИФМЕТИЧЕСКОЕ СРЕДНЕЕ


---

›  $A = \frac{1}{2}(\text{precision} + \text{recall})$

›  $\text{precision} = 0.1$

›  $\text{recall} = 1$

›  $A = 0.55$



# АРИФМЕТИЧЕСКОЕ СРЕДНЕЕ


---

›  $A = \frac{1}{2}(\text{precision} + \text{recall})$

›  $\text{precision} = 0.55$

›  $\text{recall} = 0.55$


›  $A = 0.55$



# МИНИМУМ

---

›  $M = \min(\text{precision}, \text{recall})$



# МИНИМУМ


---

›  $M = \min(\text{precision}, \text{recall})$

› precision = 0.05

› recall = 1

›  $M = 0.05$



# МИНИМУМ

---

›  $M = \min(\text{precision}, \text{recall})$

› precision = 0.4


› recall = 0.5

›  $M = 0.4$

› precision = 0.4


› recall = 0.9

›  $M = 0.4$



# F-MEPA

$$\textcolor{red}{\rangle} F = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$



# F-MEPA

›  $F = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$

› precision = 0.4


› recall = 0.5

›  $F = 0.44$

› precision = 0.4

› recall = 0.9

›  $F = 0.55$





# F-MEPA

---


$$\triangleright F_{\beta} = (1 + \beta^2) \frac{\text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$$

# F-MEPA

›  $F_{\beta} = (1 + \beta^2) \frac{\text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$

›  $\beta = 0.5$

› Важнее полнота




# F-MEPA

›  $F_{\beta} = (1 + \beta^2) \frac{\text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$

›  $\beta = 2$

› Важнее точность



# РЕЗЮМЕ

---

- › Лучший способ объединения точности и полноты —  $F$ -мера
- › Сглаженный минимум
- › Можно использовать параметр  $\beta$  для балансировки точности и полноты

# КАЧЕСТВО ОЦЕНОК ПРИНАДЛЕЖНОСТИ КЛАССУ

---

# КЛАССИФИКАТОР

---

› Частая ситуация:

$$a(x) = [b(x) > t]$$

›  $b(x)$  — оценка принадлежности классу +1

# ЛИНЕЙНЫЙ КЛАССИФИКАТОР

---

$$a(x) = [\langle \mathbf{w}, x \rangle > t]$$

»  $b(x) = \langle \mathbf{w}, x \rangle$  — оценка принадлежности классу +1

# ОЦЕНКА ПРИНАДЛЕЖНОСТИ

---

- › Как оценить качество  $b(x)$  ?
- › Порог выбирается позже
- › Порог зависит от ограничений на точность или полноту



# ОЦЕНКА ПРИНАДЛЕЖНОСТИ


---

- › Пример: кредитный скоринг
- ›  $b(x)$  — оценка вероятности возврата кредита
- ›  $a(x) = [b(x) > 0.5]$
- ›  $\text{precision} = 0.1, \text{recall} = 0.7$
- › В чём дело — в пороге или в алгоритме?

# PR-КРИВАЯ

---

- › Кривая точности-полноты
- › Ось *X* — полнота
- › Ось *Y* — точность
- › Точки — классификаторы при последовательных порогах




# Р-КРИВАЯ

---

|        |      |      |      |      |      |      |
|--------|------|------|------|------|------|------|
| $b(x)$ | 0.14 | 0.23 | 0.39 | 0.52 | 0.73 | 0.90 |
| $y$    | 0    | 1    | 0    | 0    | 1    | 1    |

# РР-КРИВАЯ


---



# PR-КРИВАЯ

---

- › Левая точка:  $(0, 0)$
- › Правая точка:  $(1, r)$ ,  $r$  — доля положительных объектов
- › Для идеального классификатора проходит через  $(1, 1)$
- › **AUC – PRC** — площадь под PR-кривой



# ROC-КРИВАЯ

---

› Кривая точности-полноты

› Ось  $X$  — False Positive Rate

$$FPR = \frac{FP}{FP + TN}$$

› Ось  $Y$  — True Positive Rate

$$TPR = \frac{TP}{TP + FN}$$


# ROC-КРИВАЯ

---

|        |      |      |      |      |      |      |
|--------|------|------|------|------|------|------|
| $b(x)$ | 0.14 | 0.23 | 0.39 | 0.52 | 0.73 | 0.90 |
| $y$    | 0    | 1    | 0    | 0    | 1    | 1    |

# ROC-КРИВАЯ

---






# ROC-КРИВАЯ

---

- › Левая точка:  $(0, 0)$
- › Правая точка:  $(1, 1)$
- › Для идеального классификатора проходит через  $(0, 1)$
- › **AUC – ROC** — площадь под ROC-кривой



# AUC-ROC

---

$$FPR = \frac{FP}{FP+TN} \quad TPR = \frac{TP}{TP+FN}$$

- › *FPR* и *TPR* нормируются на размеры классов
- › **AUC – ROC** не поменяется при изменении баланса классов

# AUC-ROC

---

$$FPR = \frac{FP}{FP+TN}$$

$$TPR = \frac{TP}{TP+FN}$$

- › **AUC – ROC** не поменяется при изменении баланса классов
- › Идеальный алгоритм: **AUC – ROC = 1**
- › Худший алгоритм: **AUC – ROC =  $\frac{1}{2}$**

# AUC-PRC

---

$$\text{precision} = \frac{TP}{TP+FP} \quad \text{recall} = \frac{TP}{TP+FN}$$

- › Точность поменяется при изменении баланса классов
- › **AUC – PRC** идеального алгоритма зависит от баланса классов
- › Проще интерпретировать, если выборка несбалансированная

# ПРИМЕР

›  $AUC - ROC = 0.95$

›  $AUC - PRC = 0.001$

$b(x) = 0$

50000  
объектов

$y = -1$

100 объектов  
 $y = +1$

950000  
объектов

$y = -1$

$b(x) = 1$

 **МФТИ**

# ПРИМЕР

› Выберем конкретный классификатор

›  $a(x) = 1$  — 50095 объектов

› Из них:  $FP = 50000$ ,  $TP = 95$

›  $TPR = 0.95$

›  $FPR = 0.05$

›  $\text{precision} = 0.0019$

›  $\text{recall} = 0.95$

$b(x) = 0$

50000  
объектов  
 $y = -1$

~~100 объектов~~  
 $y = +1$

950000  
объектов  
 $y = -1$

$b(x) = 1$

МФТИ

# РЕЗЮМЕ

---

- › Часто нужно оценивать качество модели до выбора порога
- › Площадь под кривыми:  
**AUC – ROC** и **AUC – PRC**
- › **AUC – ROC** не зависит от изменений баланса классов и лучше интерпретируется
- › **AUC – PRC** выразительнее в случае дисбаланса классов